

1 Moe 通信算子优化手册

1.1 引言

在大规模 MoE 模型分布式推理中，通信性能已成为制约系统吞吐量的核心瓶颈。MoE 模型分布式推理通信具有通信频繁、模式不固定、对端多、数据离散等特点；920F 是一款面向 HPC 领域、众核 ARM 架构，要在 920F 上获取通信极致性能，需要综合考虑通信库、通信算法/网络方面的优化。

MPI 是 HPC 领域通信事实标准，传统 MPI 通信库如 OpenMPI 对 MoE 场景支持不友好，具体表现为以下三个方面：

（1）多线程场景支持不友好

MPI 标准最初是为多进程设计，尽管 MPI 定义了四种线程支持级别，但唯一允许完全并发多线程通信的 `MPI_THREAD_MULTIPLE` 会带来极大的开销。大多数 MPI 实现采用全局锁或粗粒度同步机制来保证线程安全，在高并发场景下会产生严重的锁竞争。即便是高度优化的 MPI 库，也无法随着线程数量增加实现良好的扩展性。

（2）非连续数据传输支持不友好

MPI 语义支持连续数据与用户自定义数据类型（非连续）通信；对自定义数据类型，当前主流 MPI 实现会通过拷贝的方式将非连续数据转化为连续数据类型（pack），完成接收后再根据数据类型信息转化为目标非连续数据（unpack）；即 MPI 内部会对非连续数据进行 pack 与 unpack，且由于 MPI 线程支持不友好，pack 与 unpack 均为单线程执行，严重影响性能。连续数据块逐个发会引入通信下发与完成处理开销，对于 MoE 中大量离散 token 数据场景，性能不可接受。

（3）硬件特性细粒度控制不足

MPI 为追求跨平台兼容与标准化，对 RDMA 硬件进行了高度同质化的保守封装，仅暴露极少原生能力，导致消息传输与同步机制缺乏细粒度控制；其中问题之一是强制以单个消息为最小粒度进行传输同步与完成通知管理，无法利用硬件原生的批量请求和保序能力实现消息聚合同步及完成事件合并，使上层失去对消息处理逻辑与完成队列事件（CQE）数量的控制。在 MoE 等需要高频批量小包通信的场景中，这一短板会造成远超必要数量的 CQE 洪流，引入额外 RTT 延迟与

沉重 CPU 中断开销，无法发挥 RDMA 极致性能。

同时，由于 MoE 模型的通信模式具有不确定性，在同一网络拓扑下极易引发路由冲突与链路竞争，导致通信性能抖动与带宽利用率下降。此外，推理流程中的通信密集、交互频繁，易出现跨 MOE 层数调用通信算子的问题，如果通过每层添加全局同步的方式防止出现数据读写竞争，则会大幅吸收推理流程中的负载不均衡，降低推理吞吐。因此在算法层面分别提出了静态路由和双缓冲技术来解决上述问题。

MPI 单边通信接口结合全局同步的初版实现，在 DP16、BS128、8 路由专家场景下的实测有效带宽如表 1-1 所示，RDMA 带宽利用率仅 5.7%，通信算子各阶段时延拆解如图 1-1 所示。

Dispatch #EP	通信时延	单节点 RDMA 带宽	Combine #EP	通信时延	单节点 RDMA 带宽	峰值带宽
256	600us	11.39 GB/s	256	1400us	9.77 GB/s	200 GB/s

表 1-1 MPI 单边通信版本 MOE 算子性能




图 1-1 MPI 通信各阶段数据示意图

为突破上述限制，我们基于 VERBS 构建了底层的原子通信库 Kurmcl，提供基础的单边通信能力；并基于 Kurmcl 设计了 Dispatch 与 Combine 集合通信算法。该方案将 token 分发/汇聚逻辑与底层 RDMA 硬件原语深度融合，结合静态路由规划、双缓冲流水等技术，消除了 MPI 抽象层带来的性能损耗，有效规避了多线程安全问题，并实现了对网卡行为的精细调度。实验表明，上述优化手段显著降低了通信开销，大幅提升了大规模 MoE 推理的整体吞吐性能。

1.2 背景介绍

1.2.1 MoE 架构与专家并行

混合专家模型是当前大语言模型扩展的主流架构，其核心思想是将模型参数划分为多个独立的“专家”子网络，每个输入 token 仅激活其中少数几个专家进行计算。这种稀疏激活机制使得 MoE 模型能够在保持较低计算成本的同时，大幅提升模型容量和性能。为了在多设备或多核环境下高效部署这类模型，专家并行成为一种关键的分布式策略。它将不同专家分配到不同的计算单元上，通过跨计算单元通信完成协同计算，进一步提升模型的整体容量与效率。

1.2.2 通信算子原理

Dispatch 与 Combine 是 MoE 专家并行推理的核心通信算子，本质上是针对 MoE 稀疏非对称通信特征定制的稀疏 All-to-All 通信原语，算子通信流程如图 1-2 所示。




图 1-2 MoE 通信算子流程

Dispatch 阶段，根据门控网络（Gate）输出的专家路由权重，将当前设备上的多个 token，按照目标专家所在进程，从离散地址按需抽取，多对多散发至对应计算设备，同时携带元数据信息指导专家计算。其本质是稀疏、不规则、细粒度的全对全收集操作，数据访问高度离散，无法直接使用连续内存通信。

Combine 阶段，收集来自多个源设备的、属于同一 token 的专家计算结果，即 Dispatch 的逆向过程，随后完成加权求和，最终完成 MoE 层的输出结果整合，其本质是分布式加权规约操作。

结合两算子通信特征，对 VERBS 接口进行封装实现非连续数据零拷贝功能，同时采取多核无锁并行和 RDMA RC 保序 Notify 机制减少同步开销提升处理效率。在实现层面通过静态路由方案将随机 All-to-All 通信模式转换为固定点对点通信，尽可能避免路由冲突，搭配双缓冲技术消除全局屏障，充分释放 920F 的计算与网络能力，大幅提升了大规模集群下的 MoE 通信效率。

1.3 通信算子优化方案

1.3.1 多核无锁并行

为充分释放鲲鹏 920F 处理器众核特性，本方案在框架设计上通过以通信对端(qp)为粒度独立分配资源来避免锁竞争，发挥多线程优势；具体来说，与 qp 相关的资源如 sq、rq、cq 以及相关数据结构均独立分配；同时在业务层面确保每个通信对端的通信数据只由一个线程处理与下发，避免驱动内部以及通信库软件层面的锁竞争问题；另一方面，在通信数据准备上，本方案基于并行计算框架实现了多维度无锁并行任务划分，方案将通信对、Token 索引等任务按集群规模或线程组维度进行切分，每个线程处理固定的对端进程或 Token 范围，确保任务划分的均衡性。同时，消息组装列表、计数器等关键数据结构均按进程维度独立寻址，线程间不存在共享状态的写冲突，从设计上避免了锁竞争的产生。此外，进程内多线程间的通信数据交互，进程内的数据交换通过共享内存窗口实现，配合轻量级内存屏障完成同步，替代了传统的重量级锁同步机制。

1.3.2 RDMA 批量传输机制

本方案利用 RDMA 硬件原生支持的非连续数据批量传输机制，解决传统 MPI 仅支持连续地址块发送，导致多个不连续数据需多次调用通信接口、下发操作开销过大的问题，以及 MPI 自定义数据类型难免的数据拷贝问题。在 MoE 的 Dispatch 和 Combine 通信阶段，发送方会将多个不连续的本地数据缓冲区地址、长度以及对应的远程目标地址信息，统一记录在描述列表中，形成一个完整的传输任务集合如图 1-3 所示。完成描述列表构建后，仅需调用一次通信接口将任务下发至发送队列，触发所有非连续数据块的传输，RDMA 硬件会自动根据描述列表中的信息，将多个离散的数据依次传输到目标进程的对应内存地址，无需

软件层进行多次拆分发送。




图 1-3 离散数据批量传输示意图

这种机制大幅减少了通信接口的调用次数，避免了多次下发操作带来的软件栈开销，同时减少了 CPU 在通信路径上的干预，充分释放了 RDMA 硬件的传输能力，达成零拷贝的目的，在需要传输大量离散 Token 数据的情况下，可显著降低通信延迟，提升整体传输效率。

实验测得发送方单次 post 一个 7KB 数据包的软件开销为 600ns，在 EP256，BS64，32 线程负载均衡场景下，优化前每个线程需向对端进程各下发 8 个 WR，优化后仅需要向每个对端进程下发 1 个 WR，则优化前后数据如表 1-2 所示。

	优化前	优化后
单线程 post 次数	8	1
时延(ns)	4800	600

表 1-2 RDMA 批量传输优化对比

1.3.3 RDMA Notify 机制

为了利用 RDMA 可靠连接（RC）的硬件保序特性，因此方案中设计了轻量级的 Notify 机制，进一步降低通信同步开销。在传统 RDMA 通信模式中，为确保数据可靠到达，接收方往往需要对每个数据包的完成状态进行逐一确认，或发送方需要为每个请求触发完成事件通知，这在 MOE 这种需批量传输大量小数据包的场景下，会产生大量的完成队列事件（CQE），增加 CPU 处理开销与同步延迟。而 RDMA RC 队列对本身具备硬件级的保序与可靠传输保证，数据包严格按照发送顺序到达接收方，且不会出现丢包或乱序。




图 1-4 Notify 机制示意图

基于这一特性，方案在发送端批量发送数据时，仅在最后一个 RDMA 写入请求中携带立即数（Immediate Data），同时仅对该最后一个请求设置完成事件通知；接收方则只需等待并接收这一个带立即数的完成事件，即可确定此前所有数据包均已按序可靠到达，无需对每个数据包进行单独确认。该机制大幅减少了 RDMA 通信中的完成事件数量，降低了收发双方的 CPU 开销，同时避免了逐个确认带来的延迟累积。

实验测得发送方单次 poll cqe 的软件开销为 300ns，记一个对端进程产生的 cqe 个数为 N，则方案可将 poll cqe 的时延由 $300 * N$ ns 缩短至 300 ns，在 EP256，BS64，32 线程负载均衡场景下，单个线程需处理的对端进程 cqe 数量从 8 个优化为 1 个，则优化前后数据如表 1-3 所示。

	优化前	优化后
单线程 poll 次数	8	1
时延(ns)	2400	300

表 1-3 RDMA Notify 机制优化

1.3.4 静态路由

据 MOE 的通信原理可知，每次调用 Dispatch 时会每个 token 随机发往多个专家，即整个集群在短时间产生随机、无规律的 All-to-all 流量，Combine 阶段同理。




图 1-5 Dispatch 路由冲突示意图

如图 1-5 所示，我们发现这种乱序无规则突发流量的通信模式极易产生路由冲突问题，具体表现为部分通信链路的带宽大幅度下降，延长单次 MOE 通信的时延，显著降低整个集群的吞吐。在这个路由过程中，如图 1-6 所示的进程 0、进程 1、进程 9 与进程 248 组成的通信链路中存在着流量冲突问题：由进程 0 至进程 9、进程 248 至进程 1 这两条数据流存在明显的带宽下降问题。




图 1-6 进程间通信链路示意图

为了分析该问题，如图 1-7 所示我们结合 920F 的网络交换机的拓扑结构绘出了这两条带宽数据异常的数据流在交换机中的端口流向示意图。




图 1-7 冲突数据流在交换机中拓扑示意图

从图中可以观察到，两条数据流在 L2 层向 L1 层发送（由 SW4 至 SW2）时，由于交换机配置，二者发送端口，接收端口均一致，因此产生了因数据流竞争导致的网络带宽减半的问题。

为解决此问题，我们修改通信实现逻辑，将 MOE 无规则不固定的通信模式转换为固定的通信模式——在每次通信过程中，限定不同 DP 间，具有相同 `loacl_rank` 编号的进程进行 RDMA 通信，随后再通过共享内存，将 token 搬运至对应专家。




图 1-8 静态路由示意图

在 EP=256, BS=64, 负载均衡条件下，优化后通信算子的带宽利用率变化如下：

	动态路由	静态路由	提升幅度
Dispatch	27%	71%	163%
Combine	57%	82%	44%

表 1-4 静态路由优化对比图

1.3.5 双缓冲机制

缓冲的核心设计目标是彻底消除 MOE 通信过程中的全局同步屏障，这是整个推理过程中较为关键的性能优化点之一。在传统 MOE 通信实现中，由于进程在多层推理过程中使用同一组接收缓冲区和元数据空间，必须在每一层 MOE 通

信操作前插入全局屏障，以确保所有进程都已完成上一层的 Combine 操作，不会被下一轮的Dispatch操作覆盖仍在被读取的元数据接收缓冲区，避免出现读写冲突。然而全局屏障在大规模集群上放大负载不均衡问题，导致大量进程陷入空闲等待，整体吞吐下降显著。结合静态路由方案及通信流程分析，可能的冲突场景如下：




图1-9 双缓冲机制示意图

元数据携带MOE通信过程中的token去向和计算算子的数据处理范围信息，Dispatch阶段进行跨进程写操作修改其他进程的元数据以标识token从哪里接收，Combine阶段读取元数据将经过专家计算后的token返回给源进程，如果此时元数据信息被下一次Dispatch算子修改，则会产生严重的功能问题。

综上，仅需将存放元数据的BUFFER设计为双缓冲，即可解决导致的读写冲突问题，其内存开销低至几十KB。本方案通过维护迭代计数器的奇偶状态，实现乒乓式双缓冲机制，在 Dispatch 阶段通过迭代计数器的奇偶性切换元数据缓冲区的基地址，奇数层使用第一组元数据缓冲区，偶数层使用第二组；在 Combine 阶段则通过迭代计数器交替选择两组完全独立的元数据缓冲区作为当前操作的数据源。

这种设计使得不同进程可以在不同的缓冲区上独立工作，无需等待所有进程到达同一同步点，彻底消除了全局同步的需求，同时第 N 层的通信和计算操作与第 N+1 层的操作在不同缓冲区上进行，完全隔离了读写操作，不存在数据覆盖风险。优化后可消除序列长度 $\times$ MOE层数的全局同步操作，端到端推理时延降低7%。

1.4 通信算子优化性能

经由上述过程优化，DeepSeek应用中Dispatch和Combine通信算子, 在 EP=256, BS=64，负载均衡条件下优化后的性能如下所示：

Dispatch #EP	时延	单节点 RDMA 带宽	Combine #EP	时延	单节点 RDMA 带宽	峰值带宽
256	48 us	142 GB/s	256	84 us	163 GB/s	200 GB/s

表 1-5 通信算子性能

在带宽利用率方面，相比于MPI通信原语在该推理场景下大约6%的带宽利用率，优化后的通信算子带宽利用率提高至80%左右，实现了高效优化。